

Pusan National University
Computer Science and Engineering
Interim report

LeRobot SO-101을 활용한 지능형 로봇 팔 제어
중간보고서



팀 : 선넘지마

분과 : 하드웨어 · 보안

202155520 김도환 dowhan1225@pusan.ac.kr

202155616 천성민 russoll@pusan.ac.kr

202255540 김혜은 ww3700@pusan.ac.kr

지도 교수 : 백윤주

1. 요구조건 및 제약 사항 분석에 대한 수정사항	4
1.1 해결해야 할 과제	4
1.2 초기 요구 조건 : ACT-only end-to-end.....	4
1.3 ACT-only 실험 후 수정된 요구조건.....	4
1.4 현실적 제약 사항	5
1.5 제약사항 대응	5
2. 설계 상세화 및 변경 내역.....	6
2.1 전체 실험 흐름	6
2.2 ACT-only 설계	6
2.3 ACT-only에서 확인된 문제	6
2.4 OpenCV + FSM + ACT 설계.....	6
2.5 Diffusion Policy 도입 설계.....	8
2.6 시스템 구성.....	8
3. 구성원별 진척도	9
4. 보고 시점까지의 과제 수행 내용 및 중간 결과	11
4.1 실험 환경 구축.....	11
4.2 1단계: ACT-only 데이터 수집과 학습.....	12
4.3 데이터셋 수집 전략의 단계적 변화와 고려사항	12
4.4 ACT-only 모델 실험 현황 및 모델 계보.....	14
4.5 ACT-only 중간 결과와 한계.....	16
4.6 2단계: OpenCV + FSM + ACT 구현.....	16
4.7 OpenCV + FSM + ACT 중간 결과와 한계	17
4.8 3단계 예비 실험: Diffusion Policy 적용	19
4.9 중간 결과 종합	19
4.10 중간 결론.....	20

5. 갱신된 과제 추진 계획 및 향후 계획	22
5.1 OpenCV + FSM + ACT 기본 개발 경로	23
5.2 조명과 그림자에 대한 OpenCV 개선	23
5.3 기본 구조 실패 시 대체 방안	24
5.4 Task 1 전체 시스템 통합	24
5.5 Task 2 순차 적층	25
5.6 최종 평가 환경 및 결과 정리	25

1. 요구조건 및 제약 사항 분석에 대한 수정사항

1.1 해결해야 할 과제

본 과제에서 해결해야 할 핵심 문제는 LeRobot SO-101 로봇팔이 테이블 위에 무작위로 배치된 서로 다른 색상의 4cm × 4cm × 2cm 블록 5개를 인식하고, 각 블록을 집어 20cm × 10cm 목표 영역 안으로 안정적으로 옮기는 것이다. 1차 목표는 제한 시간 3분 이내에 5개의 블록을 모두 목표 영역에 배치하는 것이며, 2차 목표는 별도로 재배치된 5개의 블록을 제한 시간 5분 이내에 순차 적층하는 것이다.

이 과제는 단순히 한 개의 블록을 집어 옮기는 문제가 아니다. 로봇은 매 시점마다 다음에 집을 블록을 선택해야 하고, 선택한 블록으로 접근해야 하며, wrist camera를 이용해 마지막 위치를 보정하고, gripper를 닫아 블록을 안정적으로 들어 올려야 한다. 이후 목표 영역으로 이동해 블록을 놓고, 다시 다음 블록을 찾는 과정을 반복해야 한다. 따라서 perception, target selection, motion control, grasping, placing, recovery가 모두 연결된 통합 문제이다.

1.2 초기 요구 조건 : ACT-only end-to-end

초기 요구조건은 ACT(Action Chunking with Transformers)를 이용한 end-to-end 조작을 중심으로 설정하였다. 로봇은 top camera와 wrist camera를 모두 입력으로 받고, 사람이 teleoperation으로 시연한 pick-and-place 데이터를 학습하여 5개 블록을 순차적으로 목표 영역으로 옮기는 것을 목표로 했다. 이 단계에서는 별도의 OpenCV 검출기나 FSM을 두지 않고, ACT가 관측 이미지와 로봇 state를 바탕으로 전체 action sequence를 생성하도록 하는 것이 핵심이었다.

1.3 ACT-only 실험 후 수정된 요구조건

ACT-only 실험을 먼저 충분히 진행한 결과, 전체 task를 하나의 정책에 모두 맡기는 방식은 무작위 5블록 조건에서 안정성이 부족했다. 초기 1~2개 블록에서는 목표 방향으로 움직이거나 집기 동작이 나타났지만, 반복 task가 길어지고 다음에 집을 블록을 선택해야 하는 상황에서는 행동이 흔들렸다. 특히 모델이 top camera로 전체 작업 공간을 판단하기보다 wrist camera에 보이는 블록에 강하게 의존하는 경향이 확인되었다.

이에 따라 요구조건은 ACT-only에서 바로 OpenCV+ACT로 섞어 시작한 것이 아니라, ACT-only의 한계를 확인한 뒤 단계적으로 수정되었다. 수정된 방향은 top camera 기반 인식과 target selection은 OpenCV가 담당하고, 상태 전이와 pre-grasp 이동은 FSM/scripted motion이 담당하며, ACT는 wrist camera 기반 근접 grasp/lift primitive에 집중하도록 하는 것이다.

1.4 현실적 제약 사항

첫 번째 제약은 데이터 수집 난이도이다. 5개 블록이 무작위로 놓인 전체 task를 ACT-only로 학습하려면 가능한 배치, 집기 순서, 목표 영역 상태가 충분히 데이터에 포함되어야 한다. 하지만 비슷한 장면에서 다른 블록을 먼저 집는 시연이 섞이면 모델 입장에서는 같은 입력에 대해 여러 정답 action이 존재하게 된다.

두 번째 제약은 카메라 안정성이다. top camera와 wrist camera는 record와 inference에서 같은 밝기, FPS, 시야를 유지해야 한다. USB hub 사용 시 frame drop, old frame, warmup timeout이 발생할 수 있고, 자동 노출이나 white balance가 켜져 있으면 같은 블록도 매번 다르게 보일 수 있다.

세 번째 제약은 추론 속도이다. GPU가 없는 PC에서 policy inference를 수행하면 목표 FPS를 유지하기 어렵고, 관측과 제어가 늦어질 수 있다. 따라서 현재는 RTX 3090 GPU 서버에서 policy server를 실행하고, 로봇을 제어하는 PC는 robot client로 관측값을 보내는 구조를 사용한다.

네 번째 제약은 grasp 자체의 난이도이다. 블록은 작고, gripper가 블록의 평행한 두 면을 정확히 잡아야 한다. 블록 yaw, wrist camera 시야, gripper 접근 각도가 조금만 달라져도 블록을 밀거나 놓칠 수 있다. 따라서 전체 task보다 grasp primitive 자체를 먼저 안정화할 필요가 있다.

다섯 번째 제약은 조명과 그림자에 따른 OpenCV 인식 불안정성이다. 현재 top camera 영상은 주변 조명, 시간대 및 로봇팔의 위치에 따라 작업판 밝기가 달라지며, 특히 작업 공간의 좌우 하단에서 밝기 편차와 그림자가 크게 발생한다. 이로 인해 동일한 블록이라도 색상값이 다르게 측정되거나, 블록과 그림자가 하나의 contour로 합쳐져 블록의 중심과 크기가 잘못 계산되는 문제가 나타났다. 따라서 고정된 색상 threshold만으로는 평가 환경 변화에 안정적으로 대응하기 어렵다.

1.5 제약사항 대응

불량 episode를 제거한 clean dataset을 구성하였다. 또한 task를 전체 episode만으로 학습시키는 대신, ACT-only baseline, wrist-visible all-stages, grasp-specific dataset 순서로 데이터셋을 분화하였다. 카메라는 노출과 white balance를 고정하고, USB hub 연결 조건을 정리하였다. 학습과 추론은 GPU 서버로 분리하였으며, 최종 평가를 고려하여 Docker 기반 환경 재현도 준비하고 있다.

OpenCV 인식 안정화를 위해 카메라의 자동 노출, gain 및 white balance를 수동값으로 고정하고, 작업판 양쪽에 확산 조명을 배치하여 특정 방향의 강한 그림자를 줄일 계획이다. 또한 색상만으로 블록 후보를 직접 검출하지 않고, ROI와 배경 차분 및 contour를 이용하여 물체 후보를 먼저 검출한 뒤 후보 내부의 색상을 분류하는 구조로 개선한다. 조명 변화가 큰 경우에는 밝기 정규화, 여러 frame의 검출 결과 누적 및 학습 기반 segmentation을 후속 대안으로 적용한다.

2. 설계 상세화 및 변경 내역

2.1 전체 실험 흐름

설계 변경은 ACT-only 실험을 충분히 수행한 뒤, 그 결과를 바탕으로 OpenCV + FSM + ACT 구조로 전환하는 순서로 진행되었다. 따라서 본 보고서의 설계 설명도 ACT-only 설계, ACT-only 한계, OpenCV + FSM + ACT 설계, Diffusion Policy 비교 준비 순서로 정리한다.

최종 시스템에서는 Task 1과 Task 2 모두 동일한 신경망 모델 하나를 사용한다. 기본 개발 경로에서는 OpenCV와 FSM이 perception 및 decision을 담당하고 ACT가 grasp/lift를 수행한다. 해당 구조가 목표 성능에 도달하지 못하는 경우에는 YOLO를 단일 인식 모델로 사용하고 제어를 규칙 기반으로 구성하거나, ACT를 SmolVLA로 교체하는 대체 경로를 검토한다. 여러 후보 모델은 실험 과정에서 비교할 수 있지만 최종 평가에서는 하나의 신경망 모델만 선정한다.

2.2 ACT-only 설계

ACT-only 설계에서는 top camera, wrist camera, robot state를 모두 ACT policy의 입력으로 사용하였다. 모델은 일정 길이의 action chunk를 생성하고, robot client는 이를 순차적으로 실행한다. 초기에는 이 방식이 가장 단순하고, 사람이 시연한 전체 pick-and-place 흐름을 그대로 학습할 수 있을 것으로 기대하였다.

그러나 실제 task에서는 ACT가 명시적인 물체 검출기나 planning module이 아니기 때문에 한계가 있었다. ACT는 장면에서 블록 좌표를 계산한다기보다, 유사한 관측에서 사람이 보였던 행동을 모방한다. 따라서 블록 1개, 좁은 위치 범위, 고정된 시작 자세에서는 가능성이 있었지만, 블록 5개가 무작위로 놓이고 집기 순서가 달라지는 상황에서는 안정성이 떨어졌다.

2.3 ACT-only에서 확인된 문제

반복 실험 결과 ACT-only는 top camera를 이용해 전체 장면을 판단하기보다 wrist camera에 블록이 보이는 상황에 크게 의존하였다. wrist camera에 블록이 보이면 어느 정도 grasp 방향으로 움직였지만, 블록이 보이지 않거나 다음에 집을 블록을 선택해야 하는 상황에서는 움직임이 약해지거나 멈추는 현상이 반복되었다. 이는 우리가 기대한 "top camera는 전체 판단, wrist camera는 미세 조정" 역할 분담이 end-to-end ACT 안에서 충분히 학습되지 않았음을 의미한다.

2.4 OpenCV + FSM + ACT 설계

ACT-only의 한계를 확인한 뒤 OpenCV + FSM + ACT 구조로 설계를 변경하였다. top camera와 OpenCV는 블록의 색상과 위치를 검출한다. 검출된 블록은 작업 공간의 구역으로 분류되고, FSM은 다음에 집을 블록과 목표 slot을 결정한다. 이후 scripted motion 또는 저장된 pose를 이용해

로봇을 pre-grasp pose까지 이동시킨다. ACT는 이 근접 조건에서 wrist camera를 이용해 grasp/lift만 수행한다.

2.4 OpenCV + FSM + ACT 하이브리드 파이프라인




그림. OpenCV와 FSM이 블록 선택 및 구역 이동을 담당하고, ACT는 pre-grasp 이후의 근접 grasp/lift 동작만 수행한다.

(그림 1. OpenCV + FSM + ACT 하이브리드 구조 파이프라인)

하이브리드 구조의 상태 흐름은 다음과 같다.

1. observe pose로 이동
2. top camera frame 수집
3. OpenCV 기반 블록 검출
4. 블록 색상 및 구역 분류
5. FSM이 다음 target block과 place slot 결정
6. pre-grasp pose로 이동
7. ACT 또는 Diffusion policy로 grasp/lift 수행
8. scripted motion으로 목표 영역 이동 및 release
9. 남은 블록에 대해 반복

2.5 Diffusion Policy 도입 설계

OpenCV + FSM 구조로 전체 흐름을 나누더라도, 근접 grasp/lift primitive가 불안정하면 전체 loop는 실패한다. 따라서 ACT grasp primitive가 불안정한 조건을 개선하기 위해 Diffusion Policy를 다음 비교군으로 도입한다.

현재 Diffusion 모델은 C1 빨간 블록 grasp 조건에서 horizon 32, n_action_steps 8, DDIM scheduler, inference steps 10으로 학습하였다. 이후 기존 OpenCV + FSM 하이브리드 파이프라인에 연결하여 간단한 예비 추론을 수행하였으나, 정책 구간에서 뚜렷한 grasp/lift 동작은 확인하지 못하였다. 따라서 현재는 모델 성능 비교 단계가 아니라 입력·출력 및 action 실행 구조를 점검하는 단계로 구분한다.

2.6 시스템 구성

현재 시스템은 로컬 로봇 제어 PC와 GPU 서버를 분리하는 구조이다. 로컬 제어 로봇 PC에는 SO-101 follower arm, top camera, wrist camera가 연결된다. robot client는 카메라 이미지와 robot state를 수집하여 GPU 서버의 policy server로 전송한다. GPU 서버는 ACT 또는 Diffusion 모델로 action을 계산하고, action을 robot client로 반환한다. robot client는 반환된 action을 follower arm에 적용한다. 이 구조는 로컬 PC의 성능 제약을 줄이고, RTX 3090 GPU 서버에서 학습과 추론을 모두 수행할 수 있게 한다.

3. 구성원별 진척도

구성원	담당 영역	보고 시점까지의 수행 내용	진척도	향후 담당
김도환	ACT-only 전체 task 모델군 분석	- 초기 baseline ACT 모델군 설정 정리 - 병합 데이터셋, clean dataset, 5블록 전체 episode 모델 비교 - chunk/action step 변경 모델의 차이 정리 - wrist-visible all-stages ACT 모델군의 한계 분석 - ACT-only가 1~2개 블록 이후 흔들리는 원인 정리	80%	- ACT-only 모델별 성공률/실패 유형 표 작성 - Hugging Face 모델별 train_config와 연결 데이터셋 검증 - chunk/action step/KL weight 변화에 따른 성능 차이 분석 - ACT-only가 top camera 정보를 충분히 활용하지 못한 원인 정리 - 최종 보고서용 ACT-only 실험
김혜은	OpenCV + ACT grasp primitive 모델군 분	- top camera 기반 OpenCV 블록 인식 흐름 정리 - 작업 공간 구역 분류 및 pre-grasp 조건 설계 - grasp_v2, grasp_red 등 ACT grasp 모델군 평가 - 구역/색상/yaw 조건별 grasp 성공 여부 기록 - OpenCV 인식 실패와 ACT grasp 실패 원인 분리	80%	- C1 빨간 블록 회전각 보강 데이터 수집 및 ACT 후속 모델 평가 - 빨간 블록의 8개 source zone 데이터 확장 - 5개 색상 통합 grasp/lift 데이터셋 구성 - 조명·그림자 조건별 OpenCV 검출 정량 평가 - OpenCV 실패 시 YOLO segmentation용 이미지 수집 및 라벨링
천성민	Diffusion 및 후속 후보 모델 분석	- ACT grasp 불안정 조건에 대한 Diffusion Policy 검토 - VQ-BeT, SmolVLA, $\pi 0.5$ 등 후속 후보 모델 조사 - 후보 모델별 필요 데이터와 적용 가능성 정리 - GPU 서버 기반 학습/추론 조건 검	80%	- Diffusion Policy 예비 실행 구조 점검 - ACT 일반화 실패 시 SmolVLA 적용 조건 및 데이터 형식 정리 - Task 1·Task 2 instruction을 포함한 단일 SmolVLA 데

		토 - policy server 구조와 후속 모델 연결 가능성 확인		이터셋 설계 - GPU 서버에서 SmoIVLA fine-tuning 및 추론 환경 검토 - 최종 단일 신경망 모델 규정에 맞는 후보 구조 비교
공통	모델 통합 실험 및 최종 성능 검증	- ACT-only 한계 분석 공동 검토 - OpenCV+FSM+ACT 구조 변경 논의 - 모델별 실패 원인 비교 - 통합 실험 결과 확인 - 중간보고서 및 발표 자료 준비	50%	- 공통 평가 기준 확정 - ACT/OpenCV+ACT/Diffusion 후보 모델 비교 - 5블록 loop 통합 실험 - stacking 확장 실험 - 최종 데모 영상 및 보고서 완성


4. 보고 시점까지의 과제 수행 내용 및 중간 결과

4.1 실험 환경 구축

Ubuntu 환경에서 LeRobot을 설치하고 SO-101 follower arm과 camera를 연결하였다. 카메라는 OpenCV backend로 입력받았으며, top camera와 wrist camera를 각각 고정 장치명으로 관리하였다. 카메라 입력 안정성을 위해 MJPG 포맷과 640x480 해상도를 기본으로 사용하고, 자동 노출과 자동 white balance를 고정하는 방향으로 세팅하였다.

학습과 추론은 지도교수 연구실에서 지원한 RTX 3090 GPU 서버에서 수행하였다. 로봇 PC에서는 SSH와 원격 접속 환경을 이용해 서버와 통신하고, 추론 시에는 robot client와 policy server 구조로 관측 이미지와 action을 주고받는다

구축 항목	구현 내용	중간 결과
OS 및 기본 환경	Ubuntu dual boot, LeRobot 환경 설치	데이터 수집 및 추론 실행 가능
원격 접속	Tailscale 및 SSH 기반 접속	GPU 서버 원격 학습/추론 가능
카메라	top/wrist camera OpenCV 입력	640x480, 25~30 FPS 기준 운용
USB 장치	USB hub와 장치명 고정	frame 안정성 문제 정리
데이터 수집	LeRobot record 기반 episode 수집	초기/정제/all-stages/grasp 데이터셋 생성
모델 학습	ACT 및 Diffusion 학습	17개 모델 학습 완료



(그림 2. Top camera에서 관측한 현재 SO-101 실험 환경)

4.2 1단계: ACT-only 데이터 수집과 학습

처음에는 ACT만을 이용해 전체 pick-and-place 과정을 수행하도록 데이터셋을 수집하였다. teleoperation으로 사람이 직접 로봇을 조작하면서 블록을 집고 목표 영역에 놓는 episode를 만들었고, 이후 데이터 수집 방식, episode 구성, 블록 개수, 학습 step, chunk size, n_action_steps, KL weight 등을 바꾸며 반복적으로 모델을 학습하였다.

이후 데이터셋 review page를 만들어 top camera와 wrist camera 영상을 episode별로 확인하였다. 이를 통해 블록이 제대로 보이지 않는 episode, 놓기 위치가 애매한 episode, 중간에 동작이 끊긴 episode를 제거하였다. 정제된 데이터셋으로 다시 학습했지만, ACT-only 방식은 여전히 전체 5블록 task를 안정적으로 수행하지 못했다.

4.3 데이터셋 수집 전략의 단계적 변화와 고려사항

데이터셋 수집 방식은 이전 모델에서 확인된 실패 원인을 반영하여 단계적으로 변경하였다. 초기에는 ACT가 전체 5블록 task를 수행하도록 데이터를 수집하였으나, 이후 episode 길이, wrist camera 의존성 및 target selection 문제를 해결하기 위해 task를 점차 단순화하였다.

1) 전체 5블록 ACT-only 데이터 수집

초기에는 ACT 하나가 전체 pick-and-place 과정을 수행하도록 데이터를 수집하였다. 모든 episode에서 follower arm의 시작 위치를 동일하게 고정하였으며, 작업 공간의 왼쪽 아래 블록부터 시작하여 시계 방향으로 5개의 블록을 차례로 목표 영역에 배치하였다.

하나의 episode 안에는 다음 동작이 모두 포함되었다.

블록 선택 → 접근 → 파지 → 목표 영역 이동 → 배치 → 다음 블록 탐색

학습 결과 초기 1~2개의 블록은 목표 영역으로 옮기는 경우가 있었지만, 이후 블록에서는 움직임이 흔들리거나 다음 블록을 선택하지 못하였다. 이에 따라 5개 블록의 전체 동작을 하나의 긴 episode로 학습하는 방식이 현재 데이터 규모에서는 어렵다고 판단하였다.

2) Stage별 단일 블록 데이터 수집

긴 episode 문제를 줄이기 위해 전체 task를 남아 있는 블록 수에 따라 여러 stage로 나누었다.

예를 들어 블록이 4개 남은 상태에서 1개를 옮기는 episode, 3개 남은 상태에서 1개를 옮기는 episode와 같이 각 episode에서 하나의 블록만 처리하도록 구성하였다. follower

arm의 시작 위치는 동일하게 고정하였으며, 각 stage별로 약 50개의 episode를 수집하였다.

이 방식은 한 episode의 길이를 줄이고 서로 다른 task 진행 상태를 학습하기 위한 것이었다. 그러나 wrist camera에 target block이 보이지 않는 경우에는 로봇팔이 블록 방향으로 충분히 접근하지 않는 문제가 나타났다.

3) Wrist camera에 target block이 계속 보이도록 수집

이후에는 episode 시작부터 종료까지 target block이 wrist camera에 지속적으로 보이도록 로봇팔의 자세와 접근 경로를 변경하였다.

이 방식에서는 블록에 접근하고 파지하는 근접 동작이 일부 개선되었다. 그러나 모델이 wrist camera 영상에 과도하게 의존하는 새로운 문제가 나타났다. top camera가 전체 작업 공간을 보여주고 있음에도 다음에 집을 블록을 선택하는 데 충분히 활용되지 않았으며, wrist camera에서 블록이 사라지면 움직임이 약해지거나 정지하였다.

따라서 target selection과 장거리 접근까지 ACT가 직접 수행하도록 하는 방식에는 한계가 있다고 판단하였다.

4) OpenCV 기반 pre-grasp 이동 후 ACT 실행

wrist camera 의존성과 target selection 문제를 줄이기 위해 OpenCV, scripted motion 및 ACT의 역할을 분리하였다.

먼저 OpenCV가 top camera 영상에서 블록의 색상과 source zone을 검출한다. 이후 scripted motion을 이용하여 해당 zone의 pre-grasp pose까지 로봇팔을 이동시키고, ACT는 해당 위치에서 근접 grasp/lift 동작만 수행하도록 데이터셋을 구성하였다.

데이터 수집 시에는 다음 기준을 적용하였다.

1. follower arm은 고정된 pre-grasp pose에서 시작하였다.
2. wrist camera가 해당 구역과 target block을 함께 관측하도록 카메라 방향을 조정하였다.
3. gripper가 가능한 한 블록 상부에서 수직으로 하강하도록 시연하였다.
4. wrist camera 영상에서 왼쪽 gripper와 블록 사이의 간격을 일정하게 유지하였다.

현재 손목 카메라 구도에서는 오른쪽 gripper가 영상에 충분히 포함되지 않는다. 따라서 왼쪽 gripper와 블록의 상대 간격을 수집 기준으로 사용하였다. 두 대상이 지나치게 가까우면 회전된 블록에 접근할 때 gripper가 블록을 찍거나 밀 수 있고, 지나치게 멀면 접근

과정에서 블록이 wrist camera 시야에서 벗어날 수 있기 때문이다.

초기 grasp 데이터에서는 같은 위치의 블록을 0도, 30도 및 60도로 배치하고, 각 회전각에서 3회씩 시연하였다. 이 방식으로 변경한 이후에는 ACT가 블록을 정상적으로 파지한 경우 scripted motion을 통한 목표 영역 이동과 release는 비교적 안정적으로 수행되었다.

이를 통해 현재 하이브리드 구조의 주요 병목은 목표 영역 이동보다 pre-grasp 이후의 근접 grasp/lift 동작이라는 점을 확인하였다.

데이터 수집 전략의 최종 방향

현재까지의 결과를 바탕으로 이후 데이터셋은 전체 task를 한 번에 수집하지 않고 다음 조건을 분리하여 단계적으로 보강한다.

블록 회전각 → source zone → 블록 색상 → 실패 조건

우선 C1 구역의 빨간 블록에 대해 약 45도 회전 조건을 추가하고, 이후 빨간 블록을 전체 source zone으로 확장한다. 해당 모델이 안정화되면 모든 색상과 source zone을 포함하는 단일 grasp/lift 데이터셋을 구성할 예정이다.

4.4 ACT-only 모델 실험 현황 및 모델 계보

본 절에서는 ACT 정책 하나가 블록 선택, 블록 접근, grasp, lift, 목표 영역 이동, release 및 다음 블록 탐색까지 전체 pick-and-place 과정을 수행하도록 학습한 ACT-only 모델들을 정리한다. ACT-only 모델군에서는 데이터셋의 병합 및 정제, action chunk 길이, 실제 실행 action 수, KL weight, camera observation 구성 및 데이터 증강 조건을 변경하며 전체 5블록 task의 수행 가능성을 확인하였다. 아래 모델들은 별도의 OpenCV 객체 검출이나 FSM 기반 target selection 없이 top camera, wrist camera 및 robot state를 입력으로 받아 전체 action sequence를 직접 생성하도록 학습하였다.

No.	모델명	모델 설명
1	eslab1234/so101_pick_and_place_20260628_v1_act	최초로 수집한 전체 pick-and-place 데이터셋을 이용한 ACT baseline이다. 전체 task를 하나의 정책이 수행할 수 있는지 확인하기 위한 기준 모델로 사용하였다.
2	eslab1234/so101_pick_and_place_20260629_v2_act	첫 번째 baseline과 동일한 학습 설정을 유지하고 후속 수집 데이터셋을 사용하여, 데이터 수집 횟수와 episode 구성 변화가 성능에 미치는 영향을 확인하였다.

3	eslab1234/pick_and_place_move_merged_v1_act	여러 수집 세션을 병합하고 학습 step을 증가시킨 모델이다. 데이터 양을 늘렸을 때 전체 동작의 재현성이 개선되는지 확인하였으나, 데이터 품질과 장기 sequence 문제가 함께 남았다.
4	eslab1234/act_pick_and_place_all_merged_v1	당시 확보한 전체 데이터셋을 병합하여 장시간 학습한 모델이다. 데이터 양만 증가시키는 방식으로 서로 다른 시연 경로와 실패 episode의 영향을 제거하기 어렵다는 점을 확인하였다.
5	eslab1234/act_pick_and_place_clean_v2_chunk40_100k	불량 episode를 제거한 clean dataset과 짧은 chunk를 사용하였다. 근거리 동작의 반응성은 일부 개선되었으나, 다음 블록 선택과 전체 5블록 반복 문제는 해결되지 않았다.
6	eslab1234/act_pick_and_place_20260704_merged_v1_chunk40_100k	2026년 7월 4일 추가 수집 데이터를 병합하고 chunk 40 조건을 적용하였다. 새로운 데이터가 기존 clean 모델보다 전체 task 안정성을 높이는지 확인하기 위한 실험이다.
7	eslab1234/act_pick_and_place_20260704_merged_v1_chunk20_150k	chunk와 action step을 더 짧게 설정하여 관측 변화에 빠르게 반응하도록 한 모델이다. 실행 반응성은 높일 수 있었지만, top camera 기반 target selection 문제는 그대로 남았다.
8	eslab1234/pick_and_place_full_d0_5blocks_v1_merged_20260705_act_c30_a20_150k	5개 블록을 순차적으로 옮기는 전체 흐름을 데이터셋에 포함하고 짧은 action 실행을 적용하였다. 초기 블록에는 접근했지만 긴 sequence에서 오차가 누적되고 다음 블록 선택이 불안정하였다.
9	eslab1234/pick_and_place_onestep_5blocks_all_stages_clockwise_wrist_visible_merged_v1_20260706_225606_act	데이터 수집 전 구간에서 현재 목표 블록이 wrist camera에 지속적으로 보이도록 시연한 모델이다. wrist camera에 블록이 보일 때의 근접 동작은 개선되었지만 전체 장면 판단 능력은 충분히 개선되지 않았다
10	eslab1234/act_wdrop_p20_aug_kl5_allstages_c50_a25_150k_20260707_203119_final	wrist dropout과 augmentation, 낮은 KL weight 조건을 적용한 실험이다. 특정 카메라에 대한 과도한 의존성을 줄이고 일반화 성능을 높일 수 있는지 확인하기 위한 모델이다.
11	eslab1234/act_wdrop_p20_default_kl10_150k_20260708_171812	wrist dropout을 적용한 all-stages 데이터 조건에서 기본 KL weight 10을 사용한 비교 모델이다. augmentation 및 KL weight를 변경한 10번 모델과 비교하여, wrist camera 의존성 감소와

		학습 설정 변화가 전체 task 동작에 미치는 영향을 확인하기 위해 사용하였다.
12	eslab1234/pick_and_place_full_ d0_5blocks_v1_merged_20260705_ act_c100_a120_150k	전체 5블록 데이터에 긴 temporal context와 긴 action 실행 구간을 적용한 모델이다. 장기 동작의 연속성은 확보할 수 있었지만, 잘못된 행동이 시작되었을 때 수정이 늦어지는 문제가 나타났다.

4.5 ACT-only 중간 결과와 한계

ACT-only 모델군은 제한된 블록 배치 또는 wrist camera에 목표 블록이 지속적으로 보이는 조건에서는 일부 pick-and-place 동작을 재현하였다. 그러나 5개의 블록이 무작위로 배치된 전체 task에서는 다음에 집을 블록을 안정적으로 선택하지 못했고, 장기 sequence가 진행될수록 작은 위치 오차와 동작 오차가 누적되었다. 특히 top camera가 전체 작업 공간을 보여주고 있음에도 모델이 wrist camera에 보이는 블록에 강하게 의존하는 현상이 반복되었다. wrist camera에서 블록이 사라지면 움직임이 약해지거나 멈추었으며, 일부 모델에서는 다른 위치로 이동하거나 바닥을 향해 잘못된 동작을 계속 수행하였다. 데이터 정제, chunk size 변경, action step 변경 및 wrist-visible 데이터 수집으로 일부 구간의 동작은 개선되었지만, OpenCV와 같은 명시적 target selection 없이 전체 5블록 task를 하나의 정책에 맡기는 구조적 문제는 해결되지 않았다. 이에 따라 전체 task를 ACT 하나로 수행하는 방향에서 벗어나, perception과 decision을 규칙 기반으로 분리한 OpenCV + FSM + ACT 하이브리드 구조로 변경하였다.

4.6 2단계: OpenCV + FSM + ACT 구현

ACT-only 실험에서 확인된 target selection과 장기 sequence 문제를 줄이기 위해 perception, decision, motion 및 learned policy의 역할을 분리한 OpenCV + FSM + ACT 하이브리드 구조로 변경하였다.

초기 OpenCV 구현에서는 HSV 색상 범위를 이용하여 각 블록을 직접 검출하였다. 그러나 주변 조명과 그림자의 변화에 따라 동일한 블록의 HSV 값이 달라졌으며, 밝기가 낮은 영역에서는 색상 mask가 끊기거나 그림자가 블록과 함께 검출되는 문제가 발생하였다.

이에 따라 최신 구현에서는 색상 정보를 블록 후보 검출의 유일한 기준으로 사용하지 않는다. 먼저 top camera 영상에서 실제 블록이 배치될 수 있는 작업 영역만 ROI로 지정하고, 로봇팔과 목표 영역 등 검출 대상이 아닌 부분은 mask로 제외한다. 이후 배경 영상과 현재 frame의 차이 및 contour 정보를 이용하여 물체 후보를 생성하고, contour의 면적, 외접 사각형의 크기, 가로:세로 비율 및 위치 조건을 적용하여 블록이 아닌 객체를 제거한다. 최종적으로 남은 후보의 경계와 그림자 영향을 줄이기 위해 contour 중앙 영역의 색상값을 분석하여 빨강, 노랑, 나무색, 초록 및 파란색으로 분류한다.

검출된 블록의 contour 중심 좌표를 기준으로 작업 공간을 총 8개의 source zone 중 하나로 분류

한다. FSM은 빨강 → 노랑 → 나무색 → 초록 → 파랑의 고정 우선순위에 따라 다음 target block을 선택하고, 해당 블록의 source zone에 대응하는 pre-grasp pose를 결정한다.

target block이 결정되면 scripted motion 또는 저장된 pose를 이용하여 로봇팔을 pre-grasp 위치까지 이동시킨다. 이후 ACT는 wrist camera와 robot state를 입력으로 받아 블록에 접근하고, gripper를 닫아 들어 올리는 근접 grasp/lift primitive만 수행한다. 블록을 들어 올린 이후에는 다시 scripted motion을 이용하여 해당 색상의 place slot으로 이동하고 release한다.

13	grasp_v2_act_c20_a10_150k	전체 task에서 grasp 단계만 분리하여 학습한 첫 번째 grasp/lift primitive 계열이다. 짧은 action 실행을 이용해 wrist camera 관측에 따라 파지 위치를 빠르게 보정하는 것을 목표로 하였다.
14	grasp_v2_act_c100_a100_100k	동일한 grasp 데이터셋에서 긴 chunk와 action step을 사용하였다. 짧은 실행 모델과 비교하여 접근부터 파지·들어 올리기까지의 연속 동작 재현성을 확인하였다.
15	grasp_red_act_c100_a100_50k	C1 구역의 빨간 블록 조건으로 문제 범위를 축소한 ACT grasp 모델이다. 전체 구역·전체 색상 문제 이전에 pre-grasp에서 파지하고 들어 올리는 기본 primitive가 학습 가능한지 검증하였다.
16	grasp_redblock_act_c100_a100_50k_v2	C1 구역에 배치된 빨간 블록만을 대상으로, pre-grasp pose에서 블록 상부로 수직 하강한 뒤 gripper를 닫고 들어 올리는 grasp/lift 동작을 학습한 ACT 모델이다. 실제 로봇에서 총 25회 평가한 결과 20회 파지 및 lift에 성공하여 80%의 성공률을 기록하였다. 다만 블록의 변이 gripper 접근 방향과 정렬된 경우에는 안정적이었으나, 블록이 약 45도 회전하여 배치된 경우 파지 실패가 집중되는 경향이 나타났다.

4.7 OpenCV + FSM + ACT 중간 결과와 한계


OpenCV + FSM + ACT 하이브리드 구조에서는 전체 task를 perception, decision, scripted motion 및 learned grasp policy로 분리하였다. top camera 기반 블록 검출, source zone 분류, 색상 우선순위 결정 및 pre-grasp pose 이동은 OpenCV, FSM 및 scripted motion이 담당하고, ACT는 pre-grasp pose에서 시작하는 근접 grasp/lift 동작만 수행한다.

현재 하이브리드 파이프라인의 최신 ACT 모델은 eslab1234/grasp_redblock_act_c100_a100_50k_v2이다. 모델의 학습 데이터는 C1 구역에 배치된 빨간 블록만을 대상으로 수집하였다. 데이터 수집 시 로봇팔은 블록의 상부에 위

치한 pre-grasp pose에서 시작하여, gripper를 거의 수직으로 하강시킨 뒤 블록을 파지하고 들어 올리는 동작을 수행하였다. 따라서 본 모델은 전체 색상과 전체 구역의 grasp를 일반화하기 위한 모델이 아니라, 제한된 조건에서 수직 grasp/lift primitive 자체를 우선 안정화하기 위한 모델이다.

실제 로봇을 이용하여 총 25회의 반복 실험을 수행한 결과, 20회에서 블록을 정상적으로 파지하고 들어 올리는 데 성공하였다. 이에 따른 현재 조건에서의 grasp/lift 성공률은 80%이다. 블록의 변이 gripper의 접근 방향과 유사하게 정렬된 경우에는 수직 하강, gripper close 및 lift가 비교적 안정적으로 연결되었다.

반면 블록이 약 45도 회전하여 배치된 경우에는 파지 실패가 집중되는 경향이 확인되었다. 이 조건에서는 gripper가 블록의 평행한 두 면을 충분히 감싸지 못하고 블록의 모서리 또는 측면에 접촉하면서, 블록을 옆으로 밀어내거나 중심에서 벗어난 상태로 gripper를 닫는 문제가 발생하였다.



(그림 3. 약 45도 회전된 C1 빨간 블록에 대한 ACT grasp 실패 사례.)

이러한 결과는 현재 데이터셋이 수직 하강을 이용한 제한된 grasp 궤적을 중심으로 구성되어 있으며, 다양한 블록 yaw에 대응하는 wrist rotation과 접근 위치 조정 시연이 충분히 포함되지 않았기 때문으로 판단된다. 즉, 현재 모델은 C1 빨간 블록의 정렬된 배치에서는 높은 성공률을 보이지만, 블록 회전각 변화에 대한 일반화 성능은 아직 부족하다.

이 결과를 바탕으로 C1 빨간 블록의 회전각 보강, 빨간 블록의 전체 source zone 확장 및 5개 색상 통합 학습을 단계적으로 진행하며, 구체적인 개발 경로와 대체 방안은 6장에서 설명한다.

4.8 3단계 예비 실험: Diffusion Policy 적용

OpenCV + FSM + ACT 하이브리드 구조에서 근접 grasp/lift 동작의 성능을 개선할 수 있는 후속 정책을 검토하기 위해 Diffusion Policy 모델을 학습하고 간단한 실제 로봇 추론 실험을 진행하였다. 본 실험은 ACT와 Diffusion Policy의 성능을 정식으로 비교하기 위한 반복 평가가 아니라, Diffusion Policy 모델을 현재의 OpenCV + FSM 하이브리드 파이프라인에 연결하여 실제 로봇에서 실행할 수 있는지를 우선 확인하기 위한 예비 실험이다. 학습한 모델은 다음과 같다.

17	grasp_C1_red_diffusion_h32_a8_ddim10_50k	C1 빨간 블록 조건에서 Diffusion Policy의 적용 가능성을 확인하기 위해 학습한 예비 모델이다. 하이브리드 파이프라인에 연결하여 간단한 추론 실험을 진행하였으나, C1 pre-grasp pose에 도착한 이후 정책에 의한 뚜렷한 grasp/lift 동작은 관찰되지 않았다. 아직 추론 설정과 action 전달 과정을 충분히 검증하지 않았으므로 모델 성능은 판단하지 않았다.
----	--	---

4.9 중간 결과 종합

항목	중간 결과	남은 문제
환경 구축	Ubuntu와 LeRobot 기반의 로봇 제어 환경을 구축하고, SO-101 follower arm, top camera 및 wrist camera를 연결하였다. GPU가 없는 로봇 제어 PC와 RTX 3090 GPU 서버를 분리하고, Tailscale, SSH, robot client 및 policy server를 이용한 원격 학습·추론 구조를 구성하였다.	Jetson Orin Nano와 GPU 평가 서버 간 최종 통신 구조를 구축하고, Docker 이미지 기반으로 평가 서버에서 동일한 환경이 재현되는지 검증해야 한다.
데이터 수집	전체 pick-and-place episode, 정제 데이터셋, wrist-visible all-stages 데이터셋 및 grasp/lift 전용 데이터셋을 단계적으로 구성하였다. 데이터셋 review를 통해 동작이 중단되거나 카메라 관측이 부적절한 episode를 제거하였다.	전체 5개 색상과 8개 source zone을 포함하는 균형 잡힌 grasp/lift 데이터가 부족하며, 특히 블록의 다양한 회전각을 포함한 추가 수집이 필요하다.
ACT-only	ACT 정책 하나가 블록 선택, 접근, grasp, lift, 목표 영역 이동, release 및 다음 블록 탐색까지 수행하도록 다수의 모델을 학습하였다. 데이터 정제, chunk size, action step, KL weight 및 카메라 관측 조건을 변경하며 실험하였다.	무작위 5블록 조건에서 다음 target block 선택이 불안정하였으며, 긴 sequence에서 오차가 누적되었다. 또한 top camera보다 wrist camera에 보이는 블록에 강하게 의존하는 경향이 나타나 전체 task를 안정적으로 완주하지 못하였다.

OpenCV/FSM	top camera 영상에서 작업 영역 ROI를 설정하고, 배경 및 contour 정보를 이용하여 블록 후보를 검출하는 구조를 구현하였다. 검출된 블록은 색상과 중심 좌표를 기준으로 8개의 source zone으로 분류하며, FSM은 빨강 → 노랑 → 나무색 → 초록 → 파랑 순서로 target block을 선택한다.	조명 방향과 그림자에 따라 block contour와 색상 분류 결과가 달라지는 문제가 남아 있다. 자동 노출·gain·white balance 고정, 확산 조명 적용, 밝기 정규화, contour 내부 색상 통계 및 연속 frame 다수결을 적용하여 환경 변화에 대한 안정성을 검증해야 한다. 규칙 기반 방식으로 충분한 정확도를 확보하지 못할 경우 학습 기반 instance segmentation을 적용한다.
OpenCV + FSM + ACT	OpenCV와 FSM이 target block을 선택하고 C1 구역의 pre-grasp pose까지 이동한 뒤, ACT가 근접 grasp/lift만 수행하는 하이브리드 구조를 구성하였다. 최신 모델인 eslab1234/grasp_redblock_act_c100_a100_50k_v2는 C1 구역의 빨간 블록을 대상으로 수직 하강 후 파지와 들어 올리기를 수행하도록 학습하였다. 실제 로봇에서 총 25회의 반복 실험을 진행한 결과 20회 성공하여 80%의 grasp/lift 성공률을 기록하였다.	현재 결과는 C1 구역의 빨간 블록이라는 제한된 조건에 해당한다. 블록의 변이 gripper 접근 방향과 정렬된 경우에는 안정적이었으나, 블록이 약 45도 회전된 경우에는 블록을 밀거나 중심을 벗어나 파지에 실패하는 경향이 나타났다. 다양한 블록의 수평 회전각(yaw), 색상 및 source zone에 대한 데이터 확장이 필요하다.
Diffusion	C1 빨간 블록의 grasp/lift 데이터를 이용하여 eslab1234/grasp_C1_red_diffusion_h32_a8_ddim10_50k 모델을 학습하고, 기존 OpenCV + FSM 하이브리드 파이프라인에 간단히 연결하는 예비 실험을 수행하였다. C1 pre-grasp pose까지의 scripted motion은 정상적으로 수행되었으나, 이후 policy 실행 구간에서 뚜렷한 grasp/lift 동작은 관찰되지 않았다	현재는 단순한 초기 적용 실험만 진행한 상태이므로 모델의 성능을 판단하거나 ACT와 직접 비교할 수 없다. observation 및 action 설정, 모델 입출력 feature, action 전달 과정과 추론 실행 조건을 확인한 뒤 실제 정책 동작이 발생하는지 다시 검증해야 한다.

4.10 중간 결론

본 프로젝트는 LeRobot SO-101 기반 Pick & Stack 과제의 1차 목표 달성을 위해 ACT-only 실험을 먼저 진행하고, 그 한계를 분석한 뒤 OpenCV + FSM + ACT 구조로 전환하

였다. 중간보고 시점의 핵심 결론은 ACT-only 방식만으로는 무작위 5블록 전체 task를 안정적으로 수행하기 어렵다는 것이다. 그 원인은 데이터 개수 부족만이 아니라, top camera 기반 목표 선택, 장기 sequence, wrist camera 의존성, grasp yaw 문제 등이 함께 작용하기 때문이다.

따라서 남은 기간에는 OpenCV + FSM + ACT 하이브리드 구조를 기본 경로로 유지하면서, C1 빨간 블록의 회전각 문제를 먼저 개선한다. 이후 빨간 블록을 전체 source zone으로 확장하고, 최종적으로 모든 색상과 source zone을 포함하는 단일 grasp/lift 모델을 학습한다. 해당 모델을 5 블록 전체 FSM loop와 연결하여 Task 1을 완성한 뒤 동일한 신경망 모델을 이용한 Task 2 적층으로 확장한다.

OpenCV 인식이 조명과 그림자 변화에 충분히 안정화되지 않는 경우에는 YOLO 기반 인식과 규칙 기반 grasp를 대안으로 검토하며, ACT가 전체 조건에 일반화되지 않는 경우에는 SmolVLA를 대체 정책으로 검토한다. Diffusion Policy는 실행 구조가 정상적으로 확인되는 경우에만 후속 비교 대상으로 사용한다.

5. 갱신된 과제 추진 계획 및 향후 계획

세부 작업 / 완료 기준	6월 4주	7월 1주	7월 2주	7월 3주	7월 4주	8월 1주	8월 2주	8월 3주	8월 4주	9월 1주	9월 2주
1. 환경 구축·원격/학습 환경 구성 Ubuntu·LeRobot·Tailscale·GPU 서버·카메라	완료										
2. ACT-only 데이터 수집·학습 전체 task·stage별·wrist-visible 데이터	완료										
3. ACT-only 한계 분석·데이터 정제 target selection·장기 sequence 한계 확인		완료									
4. OpenCV+FSM+ACT 구현·C1 빨간 블록 평가 25회 중 20회 성공, 45° 회전 취학		완료									
5. C1 빨간 블록 회전각 보강 데이터 수집 0°·15°·30°·45° 조건 추가				예정							
6. OpenCV 검출 안정화·정량화 조명·그림자·ROI·배경 contour·색상 평가				예정							
7. C1 ACT 재학습·회전각 평가 보강 데이터 학습 및 각도별 재평가					예정						
8. 빨간 블록 8개 source zone 확장 zone별 pre-grasp 보강·통합 평가					예정						
9. 5색 통합 데이터·단일 ACT 모델 Task 1·2 공통 grasp/lift 모델						예정					
10. Task 1 전체 5블록 loop·recovery 통합 재검출·재시도·timeout·place slot							예정				
11. Task 1 3분 경량평가·시간 최적화 무작위 배치 반복평가·병목 제거								예정			
12. 대체 경로 예비 검토 (필요 시 YOLO / SmolVLA) 기본 구조 성능 부족 시 적용						예정					
13. Task 2 적층 2→3→5개 확장 동일 모델 사용·5초 유지 평가									예정		
14. Jetson Orin Nano·Docker 통합 평가 서버 이전·장치 연결·재시작 검증									예정		
15. 최종 모의평가·보고서·발표 Task 1·2 반복평가·영상·보고서 완성										예정	

(그림 5. 2026년 7월부터 9월 2주차까지의 갱신된 과제 추진 계획)

그림 4는 중간보고 시점까지 확인된 결과를 바탕으로 최종보고서 제출 시점까지의 개발 일정을 정리한 것이다.

현재 가장 높은 성능을 보인 OpenCV + FSM + ACT 하이브리드 구조를 기본 경로로 설정하고, C1 빨간 블록의 회전각 보강, 전체 source zone 및 색상 확장, Task 1 통합, Task 2 적층, Jetson Orin Nano와 Docker 평가 환경 구축 순서로 진행한다. 기본 구조가 목표 성능에 도달하지 못하는 경우에는 YOLO 기반 인식 또는 SmolVLA 기반 정책을 대체 경로로 검토한다.

향후 개발은 현재 가장 높은 실제 로봇 성능을 보인 OpenCV + FSM + ACT 하이브리드 구조를 기본 경로로 진행한다. 먼저 C1 구역의 빨간 블록에서 확인된 회전각 문제를 개선하고, 이후 빨간 블록을 전체 source zone으로 확장한다. 이 단계가 안정화되면 5개 색상과 8개 source zone을 포함하는 단일 grasp/lift 모델을 학습하고, 최종적으로 5개 블록을 순차 처리하는 Task 1 전체 시스템을 완성한다.

기본 구조가 목표 성능에 도달하지 못할 경우에는 실패 지점에 따라 YOLO 기반 인식 또는 SmolVLA 기반 정책을 대안으로 검토한다. 최종 평가에서는 Task 1과 Task 2에 동일한 신경망 모델 하나만 사용하며, 블록 선택, 이동 및 적층 위치 결정은 OpenCV, FSM 및 scripted motion과 같은 규칙 기반 방식으로 처리한다.

5.1 OpenCV + FSM + ACT 기본 개발 경로

첫 번째 단계에서는 최신 ACT 모델이 취약했던 C1 빨간 블록의 회전각 문제를 개선한다. 블록을 0도, 15도, 30도 및 45도로 배치하여 회전각별 grasp/lift 데이터를 추가 수집하고, 기존 데이터셋과 병합하여 후속 ACT 모델을 학습한다. 필요하다면 OpenCV로 블록의 수평 회전각을 추정하고, ACT 실행 전에 wrist roll을 조절하여 gripper 방향을 정렬하는 방식도 비교한다.

추가 학습 후에는 기존과 동일하게 최소 25회 이상 실제 로봇 평가를 수행하고, 전체 성공률과 회전각별 성공률을 기록한다. 특히 기존에 실패가 집중된 약 45도 조건이 개선되었는지를 우선 확인한다.

C1 빨간 블록의 회전각 대응이 안정화되면 빨간 블록을 전체 8개 source zone으로 확장한다. 각 zone에서 여러 위치와 회전각으로 데이터를 수집하고, 모든 zone의 데이터를 병합하여 빨간 블록 통합 ACT 모델을 학습한다. 평가 결과 특정 zone에서만 실패가 반복되면 해당 zone의 데이터만 추가 보강한다.

빨간 블록이 전체 zone에서 안정적으로 파지되면 노란색, 나무색, 초록색 및 파란색으로 확장한다. 각 색상과 zone의 초기 데이터를 수집해 통합 모델을 학습한 뒤, 실패가 발생하는 색상·zone·회전각 조합을 중심으로 추가 데이터를 수집한다. 최종적으로 5개 색상과 8개 source zone에서 공통으로 사용할 단일 grasp/lift ACT 모델을 선정한다.

5.2 조명과 그림자에 대한 OpenCV 개선

현재 OpenCV는 주변 조명과 그림자에 따라 동일한 블록을 검출하거나 놓치는 문제가 있으므로 하드웨어 환경과 영상 처리 방식을 함께 개선한다.

카메라의 노출, gain 및 white balance를 가능한 범위에서 고정하고, 확산 조명을 이용하여 작업판의 밝기 편차를 줄인다. 영상 처리에서는 작업 영역 ROI와 비대상 영역 mask를 적용하고, 배경과 현재 frame의 차이 및 contour의 면적·크기·형태 조건을 이용하여 블록 후보를 검출한다. 색상은 그림자와 반사의 영향을 줄이기 위해 contour 중앙 영역의 평균값 또는 중앙값을 이용해 분류한다.

하나의 frame 결과만 사용하지 않고 연속된 여러 frame의 색상, 중심 좌표 및 zone 결과를 누적하여 다수결로 최종 target을 결정한다. 기본 조명, 밝은 조건, 어두운 조건 및 한쪽 방향에서 그림자가 발생하는 조건에서 블록 검출률과 색상 분류 정확도를 측정한다.

5.3 기본 구조 실패 시 대체 방안

OpenCV + FSM + ACT가 목표 성능에 도달하지 못할 경우 실패 원인에 따라 다음 대안을 적용한다.

조명과 그림자 때문에 OpenCV 인식이 안정화되지 않는 경우에는 YOLO instance segmentation을 이용하여 블록의 색상, 중심 및 회전각을 검출한다. 다만 최종 평가에서 신경망 모델을 하나만 사용해야 하므로, YOLO를 최종 모델로 선정할 경우 파지와 배치는 규칙 기반으로 구성한다.

YOLO segmentation → 블록 중심 및 회전각 계산 → FSM → pre-grasp 이동 → wrist roll 정렬 → scripted grasp/lift/place

반대로 OpenCV와 FSM은 정상적으로 동작하지만 ACT가 다양한 색상, zone 및 회전각에 일반화되지 않는 경우에는 ACT를 SmolVLA로 교체한다.

OpenCV 검출 → FSM target 선택 → pre-grasp 이동 → SmolVLA grasp/lift → scripted place 또는 stack

SmolVLA는 먼저 C1 빨간 블록의 짧은 grasp/lift episode로 적용 가능성을 확인한다. ACT 보다 안정적인 결과가 나타나는 경우에만 빨간 블록 전체 zone과 5개 색상으로 확장한다. Diffusion Policy는 현재 예비 실행 단계이므로 실제 정책 동작이 정상적으로 확인되는 경우에만 후속 비교를 진행한다.

최종 후보는 다음 세 가지 중 하나로 선정한다.

후보	신경망 모델	규칙 기반 부분
기본안	ACT	OpenCV, FSM, 이동, 배치, 적층
인식 대안	YOLO	FSM, grasp, lift, 배치, 적층
정책 대안	SmolVLA	OpenCV, FSM, pre-grasp, 배치 및 적층 보조

5.4 Task 1 전체 시스템 통합

최종 grasp/lift 모델을 선정한 뒤 OpenCV 검출, 색상 우선순위 FSM, zone별 pre-grasp 이동, 정책 grasp/lift 및 목표 영역 배치를 하나의 전체 loop로 통합한다.

하나의 블록을 처리한 뒤에는 observe pose로 복귀하여 남은 블록을 다시 검출한다. grasp에 실패하여 블록 위치가 변경된 경우 기존 위치로 즉시 재시도하지 않고, top camera로 다시 검출한 뒤 변경된 위치에서 재시도한다.

동일한 블록에 대한 최대 재시도 횟수와 각 상태의 timeout을 설정하여 무한 반복을 방지한다. 단일 블록 전체 동작, 3블록 loop, 5블록 loop 순서로 확장하고, 제한 시간 3분 이내의 성공 블록 수와 전체 수행 시간을 측정한다. 이 단계까지 완료되어야 Task 1이 완성된 것으로 판단한다.

5.5 Task 2 순차 적층

Task 2에서는 Task 1에서 최종 선정한 동일한 grasp/lift 신경망 모델을 사용한다. 블록을 들어 올린 이후의 이동과 release만 적층용 scripted motion으로 변경한다.

목표 영역 안에 하나의 적층 중심을 정하고, stack_level_1부터 stack_level_5까지 높이별 접근 pose와 release pose를 저장한다. 먼저 2개 블록 적층을 안정화하고, 이후 3개 및 5개 블록으로 확장한다.

고정 적층 pose에서 중심 오차가 누적되는 경우에는 top camera로 현재 적층물의 중심을 검출하여 다음 블록의 x,y 위치를 보정한다. 그래도 release가 불안정한 경우에만 wrist camera 기반의 짧은 적층 보정 동작 또는 SmolVLA 통합 정책을 검토한다.

각 적층 결과는 release 이후 5초 이상 유지되는지를 기준으로 평가하며, 중심 오차, 기울어짐, release 충격 및 적층 붕괴 원인을 기록한다.

5.6 최종 평가 환경 및 결과 정리

Task 1과 Task 2가 안정화되면 Jetson Orin Nano가 camera frame과 robot state를 처리하고 GPU 서버와 통신하도록 최종 시스템을 구성한다.

Docker 이미지에는 LeRobot 환경, 최종 신경망 모델, OpenCV 또는 YOLO detector, FSM 코드, source zone pose, place-stack pose 및 실행 script를 포함한다. 평가 서버에서 container를 새로 생성한 뒤 GPU, 카메라, 로봇 장치 및 네트워크가 정상적으로 연결되는지 검증한다.

9월 2주차에는 Task 1과 Task 2를 실제 평가와 동일한 조건으로 반복 수행하고, 성공 블록 수, 전체 수행 시간, 적층 유지 여부와 실패 유형을 최종 결과표로 작성한다. 최종 모델, 데이터셋, 코드, Docker 이미지, 데모 영상, 발표 자료 및 최종보고서를 함께 완성한다.